

⚙️ Configurações



- ⚙️ Em geral
- 🖨️ Mostrar
- 🔍 Amostragem
- ⚠️ Penalidades
- 👤 Agente
- 🔗 Desenvolvido

🔗 Em geral

- ☐ **Pré-preencher o cache KV após a resposta**
Após cada resposta, envie a conversa novamente para preencher previamente o cache KV do servidor. Isso torna a próxima interação mais rápida, já que o prompt já estará codificado enquanto você lê a resposta.
- ☐ **Desativar análise de conteúdo de raciocínio**
Envie reasoning_format=none para que o servidor retorne os tokens de raciocínio diretamente no código, em vez de extraí-los para um campo separado.
- ☐ **Excluir o raciocínio do contexto**
Remover o raciocínio das mensagens anteriores antes de enviá-las. Quando desativado, o raciocínio é reenviado através do campo `reasoning\_content`, permitindo que o modelo veja sua própria linha de raciocínio ao longo das interações.
- ☐ **Ativar/desativar saída bruta**
Exibir botão de alternância para exibir mensagens como texto simples em vez de conteúdo formatado em Markdown.

JSON personalizado

Parâmetros JSON personalizados para enviar à API. Devem estar em formato JSON válido.

As configurações são salvas no armazenamento local do navegador.

- ↺ Restaurar para as configurações padrão
- Salvar configurações